

TIPS-IA

Groupe : Outils d'annotation (de données)

Émilien Schultz

2025-09-27

Aujourd'hui

- Premier contact & amorçage
- Brainstormer ensemble
- Préciser objectifs/méthode/calendrier

Tour de table : rappel qui/où êtes-vous, et quels outils d'annotation avez-vous croisés ?

Dans le projet

Les grands modèles de langage (LLM) ouvrent actuellement un ensemble de nouvelles perspectives pour les SHS, que ce soit l'annotation de corpus ou l'extraction d'information. Cela pose à la fois la question de la manière de construire des corpus d'entraînement ou de test pour mettre au travail ces modèles (notamment en les entraînant pour augmenter leurs spécificités) mais aussi l'usage direct de ces modèles pour l'automatisation d'une partie ou de la totalité. Plusieurs outils (Inception, Doccano, ActiveTigger...) avec des fonctionnalités et des statuts très différents (propriétaire/libre, gratuit/payant) permettent d'annoter des corpus semi-automatiquement avec des phases d'apprentissage plus ou moins longues. L'objectif est de produire un état des lieux de ces outils suscitant beaucoup d'intérêt, à l'image de ce qui avait été réalisé par un groupe de chercheurs il y a quelques années sur la retranscription (<https://hal.science/halshs-02917916v2>). Une présentation publique de ce travail est également envisagée dans un format comme celui des Tuto@Mate

Budget : 1000e (logiciel + déplacement)

Idée générale

- L'annotation de textes est une activité importante en SHS pour interagir avec des données textuelles.
- Initialement : des humains qui enrichissent des corpus (mince ou profonde)
- Arrivée des outils de l'apprentissage automatique et de l'approche NLP/IA avec prédiction : annotation pour entrainer des modèles (pratiques IA)
- Des stratégies d'enrichissements automatiques (IA) intégrés dans les outils & explosion des ergonomies
- *Constat d'une diversité d'outils répondants à des logiques différentes*

Conséquence : des outils très divers allant de l'analyse qualitative (Nvivo, QualCoder) au NLP/IA (Argilla, Labelstudio) intégrant des stratégies d'annotation automatique.

De nombreux logiciels

- label studio : <https://labelstud.io/>
- inception : <https://inception-project.github.io/>
- doccano : <https://doccano.github.io/doccano/>
- Prodigy : <https://prodi.gy/>
- nvivo : <https://ritme.com/software/nvivo/>
- libreqda : <https://libreqda.org/>
- argilla : <https://docs.argilla.io/>
- brat : <https://brat.nlplab.org/>
- LightTag : <https://github.com/LightTag>
- QualCoder : (<https://github.com/ccbogel/QualCoder>)
- Annotation Lab : <https://nlp.johnsnowlabs.com/docs/en/alab/quickstart>
- Refinery : <https://github.com/code-kern-ai/refinery?tab=readme-ov-file>
- Label Sleuth : <https://github.com/label-sleuth/label-sleuth> <- à tester
- Brat : <https://github.com/nlplab/brat>
- Snorkel > Snorkel Flow <https://snorkel.ai/snorkel-flow/>
- Generative AI Lab + Spark NLP : <https://nlp.johnsnowlabs.com/docs/en/alab/quickstart>
- Taguette / Libre QDA <https://gitlab.com/bin-cirst/libreqda/libre-qda>
- SMART, etc.

De nombreuses différences

- texte uniquement/multimodal
- ouvert/fermé
- service/logiciel on premise

- type de tâche : classification / segmentation
- uniquement annotation/intégration ML/DL
- académique / non académique
- coloration disciplinaire/communauté d'origine
- modèles classiques / modèles encodeurs / LLM
- outil spécifique sur une tâche / plateforme avec de nombreuses fonctions (topic analysis)
- confidentiel / forte adoption
- plus maintenu / maintenu
- orienté équipe / orienté crowdworking
- orienté humain (création de l'information) / orienté automatisation (correction de la prédiction)
- ...

Approfondir ce qu'est l'annotation

Nombreuses tâches autour de 3 grandes philosophies

- enrichir un corpus (DH)
- extraire des informations à partir d'un corpus identifié
- constituer un corpus pour entraîner un modèle

Des pratiques différentes

- classification d'éléments entiers (texts) ou découpés (paragraphe, phrases)
- identification de segments ou d'entité (span pour les textes)
- identification de relations (entre des segments)
- collecter des human feedback (proposition sur lesquels arbitrer)
- distribuer les tâches sur un groupe de personnes / gérer un travail collaboratif / workload management

Formuler un objectif général (proposition)

- Proposer une grille de lecture pour se repérer dans un paysage d'outils complexes et mouvant
- S'adresser aux sciences humaines et sociales

Concrètement

- Un rapport simple et efficace qui permet de guider le choix
- Une méthodologie évolutive si jamais on veut continuer à maintenir la veille
- Prendre des notes pour éventuellement écrire un article une fois le rapport terminé
 - BMS ?

Méthodologie (proposition)

- Définir une liste de critères
- Définir une liste d'utilisateurs types/tâches/dataset
- Définir une première vague d'outils à tester
- Faire des évaluations (par pair ?)
- Restitution collective

Brainstorming 1 : pratiques types

Exemples d'utilisateurs/dataset/tâche

- base de données pour entraîner un modèle / tester > sciences sociales computationnelles
- annotation d'entretien pour une analyse thématique > sociologie & exhaustivité
- extraction d'éléments pertinents d'un grand corpus
- enrichissement sémantique de document / linguistique > linguiste
- synthèse / lecture distante de matériau / textes augmentées par l'IA pour qualitatif

Brainstorming 2 : description des logiciels

- propriétaire/ouvert
- spécialisés/plateforme
- ...

Brainstorming 3 : logiciels à retenir

- Nvivo
- Label studio
- Doccano
- Prodigy
- Argilla
- Inception
- QualCoder
- ...

Questions d'organisation

- Ouverture du nombre de participant ?
- Comment limiter le nombre de logiciels ? Quelle place donner aux critères spécifiques aux sciences sociales ? Aux pratiques intermédiaires de programmation ?
- Mise en place d'une méthodologie flexible cumulative ou se concentrer sur un petit nombre de logiciels pour amorcer la pompe ?
- Critère de qualité : écarter les logiciels plus mis à jour depuis plus de 2 ans + moins de 1000 étoiles sauf si quelqu'un veut le tester ?
- Dépôt pour les documents ? <https://gitlab.in2p3.fr/tips-ia/annotation>

Proposition de Rétroplanning

- ~~d'ici juillet 2026, mail de constitution de groupe~~
- fin août 2025, premier échange > réunion prévue le 27 août
- fin septembre 2026, identification de la liste des outils d'intérêt
- novembre 2026 rédaction d'un protocole & de jeux de données issus de la littérature
- février 2026, test des logiciels collectif et construction d'un document de travail
- avril 2026, réunion d'échange sur les logiciels et bases du rapport

Ressources

Collecter les ressources dans le framaform

- liste <https://github.com/zenml-io/awesome-open-data-annotation>
- Text Annotation Tools: A Comprehensive Review and Comparative Analysis L Colucci Cante, S D'Angelo, B Di Martino... - ... Conference on Complex ..., 2024
- Exploring large language models for qualitative data analysis. In Proceedings of the 4th International Conference on Natural Language Processing for Digital Humanities
- Moncada, Marie. « Should We Use NVivo or Excel for Qualitative Data Analysis? » Bulletin of Sociological Methodology/Bulletin de Méthodologie Sociologique 165-166, n 1-2 (avril 2025): 186-211. <https://doi.org/10.1177/07591063251317084>.